Oleksandr Oksanich, AIS ID: 122480

Umelá inteligencia

Zadanie č. 3b — klastrovanie

Obsah

Riešený problem

Máme 2D priestor, ktorý má rozmery X a Y, v intervaloch od -5000 do +5000. Tento 2D priestor treba vyplniť 20 bodmi, pričom každý bod má náhodne zvolenú polohu pomocou súradníc X a Y. Každý bod má unikátne súradnice (t.j. nemalo by byť viacej bodov na presne tom istom mieste).

Po vygenerovaní 20 náhodných bodov treba vygenerovať ďalších 40000 bodov, avšak tieto body nebudú generované úplne náhodne, ale nasledovným spôsobom:

1. Náhodne vybrať jeden zo všetkých doteraz vytvorených bodov v 2D priestore (nielen z prvých 20)
2. Ak je bod príliš blízko okraju, tak zredukovať príslušný interval, uvedený v nasledujúcich dvoch krokoch
3. Vygenerovať náhodné číslo X_offset v intervale od -100 do +100
4. Vygenerovať náhodné číslo Y_offset v intervale od -100 do +100
5. Pridať nový bod do 2D priestoru, ktorý bude mať súradnice ako náhodne vybraný bod v kroku 1, pričom tieto súradnice budú posunuté o X_offset a Y_offset

Úlohou je naprogramovať zhlukovač pre 2D priestor, ktorý zanalyzuje 2D priestor so všetkými jeho bodmi a rozdelí tento priestor na k zhlukov (klastrov).

Na riešenie problému treba použiť k-means (stred je centroid), k-medoids (stred je medoid) a divízne zhlukovanie (stred je centroid).

Za úspešný zhlukovač považujeme taký, v ktorom žiaden klaster nemá priemernú vzdialenosť bodov od stredu viac ako 500.

Oleksandr Oksanich, AIS ID: 122480

Opis riešenia

Pre túto implementáciu som použil programovací jazyk Python (verzie 3.11) a vývojové prostredie IntelliJ IDEA Ultimate (2023.3 EAP). Na vizualizáciu údajov som použil modul "matplotlib".

Reprezentácia údajov

Množina 40000+20 vygenerovaných bodov je reprezentovaná zoznamom (x, y)-dvojíc súradníc.

Použitý algoritmus

K-means (stred je centroid)

Hlavnou podstatou algoritmu K-means je výber K náhodných bodov, ktoré sa majú stať centroidmi zo z množiny údajov, priradenie každého údajového bodu k najbližšiemu centroidu (pomocou euklidovskej vzdialenosti) a iteračná aktualizácia centroidov, kým sa už výrazne nemenia (a ani zhluky) alebo kým sa nedosiahne určený počet iterácií. Centroidy sú stredové body zhlukov, ktoré predstavujú priemernú polohu všetkých dátových bodov priradených k príslušnému zhluku. Sú to čisto geometrické body, ktoré nemusia byť vždy skutočnými prvkami údajovej množiny.

```
def calculate_centroid(cluster):
    if not cluster:
        return None

    c_x = sum(point[0] for point in cluster) / len(cluster)
    c_y = sum(point[1] for point in cluster) / len(cluster)

    return c_x, c_y


def k_means(points, k, max_iterations=1000):
    start_time = time.time()

    # Initial random centroid generation
    centroids = random.sample(points, k)
    clusters = [[] for _ in range(k)]

    for _ in range(max_iterations):
        # Generate K clusters
        new_clusters = [[] for _ in range(k)]

        # Assign each point to the nearest centroid (based on the Euclidean
distance)
        for point in points:
            closest_centroid_index = min(range(k), key=lambda i:
euclidean_distance(point, centroids[i]))
            new_clusters[closest_centroid_index].append(point)

        # Check for convergence by comparing old clusters with new clusters
        if clusters == new_clusters:
            break

        clusters = new_clusters
```

```
        # Update centroids to the mean of the points within each cluster
        for j in range(k):
            if clusters[j]:
                centroids[j] = calculate_centroid(clusters[j])

    return clusters, centroids, time.time() - start_time
```

K-medoids (stred je medoid)

Algoritmus K-medoids s použitím medoidov funguje takmer rovnako ako vyššie uvedený algoritmus K-means s výnimkou spôsobu výpočtu centrálnych bodov. Medoid je najreprezentatívnejší alebo najcentrálnejší bod v zhluku, ktorý minimalizuje rozdielnosť voči všetkým ostatným bodom v zhluku. Je to skutočný údajový bod zo z dátovej množiny na rozdiel od centroidu.

```
def k_medoids(points, k, max_iterations=1000):
    start_time = time.time()

    # Initial random medoid selection
    medoids = random.sample(points, k)
    clusters = [[] for _ in range(k)]

    for _ in range(max_iterations):
        # Generate K clusters
        new_clusters = [[] for _ in range(k)]

        # Assign each point to the nearest medoid (based on the Euclidean distance)
        for point in points:
            closest_medoid_index = min(range(k), key=lambda i:
euclidean_distance(point, medoids[i]))
            new_clusters[closest_medoid_index].append(point)

        # Check for convergence by comparing old clusters with new clusters
        if clusters == new_clusters:
            break

        clusters = new_clusters

        # Update medoids by choosing the point that minimizes total distance within
clusters
        for j in range(k):
            if clusters[j]:
                # Calculate distances between points within the cluster
                distances = [sum(euclidean_distance(point, p) for p in clusters[j])
for point in clusters[j]]
                # Find the index of the point that minimizes the total distance
                min_distance_index = distances.index(min(distances))
                medoids[j] = clusters[j][min_distance_index]

    return clusters, medoids, time.time() - start_time
```

Oleksandr Oksanich, AIS ID: 122480

Divízne zhlukovanie (stred je centroid)

Algoritmus divízneho zhlukovania je prístup hierarchického zhlukovania "zhora nadol", ktorý začína priradením všetkých dátových bodov k jednému zhluku a považuje ho za koreňový zhluk, ktorý zahŕňa celý dataset. Potom sa nájde najväčší zhluk (ten, ktorý obsahuje najviac bodov) a rozdelí sa na polovicu. Na túto časť som sa rozhodol použiť K-means (K=2). Rozdelenie sa uskutoční, kým je priemerná vzdialenosť každého zhluku od jeho stredu väčšia ako 500 a počet zhlukov je menší ako veľkosť datasetu.

```
def calculate_avg_distance_from_center(cluster, center):
    return sum(euclidean_distance(center, p) for p in cluster) / len(cluster)

def divisive_clustering(points):
    start_time = time.time()

    # A single cluster in the beginning
    clusters = [points]

    successful = False

    while len(clusters) < len(points) and not successful:
        max_cluster = max(clusters, key=len)  # Find the cluster with the maximum
number of points

        if max_cluster:
            # Using K-means to halve the largest cluster
            split, _, _ = k_means(max_cluster, 2)

            # Replace the largest cluster with the two subclusters
            clusters.remove(max_cluster)
            clusters.extend(split)

            successful = not any(calculate_avg_distance_from_center(cl,
calculate_centroid(cl)) > 500 for cl in clusters)
        else:
            break

    return clusters, successful, time.time() - start_time
```

Zhodnotenie riešenia

Výsledky testovania a vizualizácia

	K-means (K=20)	**K-medoids (K=20)**	**Divízne zhlukovanie**
Čas 1, s	35.86085939	910.617033	5.324202061
Čas 2, s	17.24153161	749.2716079	3.245486021
Čas 3, s	37.66490602	907.4700212	4.215854645
Priemer	30.25576568	855.7862207	4.261847576

	K-means (K=20)	**K-medoids (K=20)**	**Divízne zhlukovanie**

Oleksandr Oksanich, AIS ID: 122480

Úspešnosť 1	Áno	Nie	Áno
Úspešnosť 2	Áno	Áno	Áno
Úspešnosť 3	Nie	Nie	Áno

1. príklad

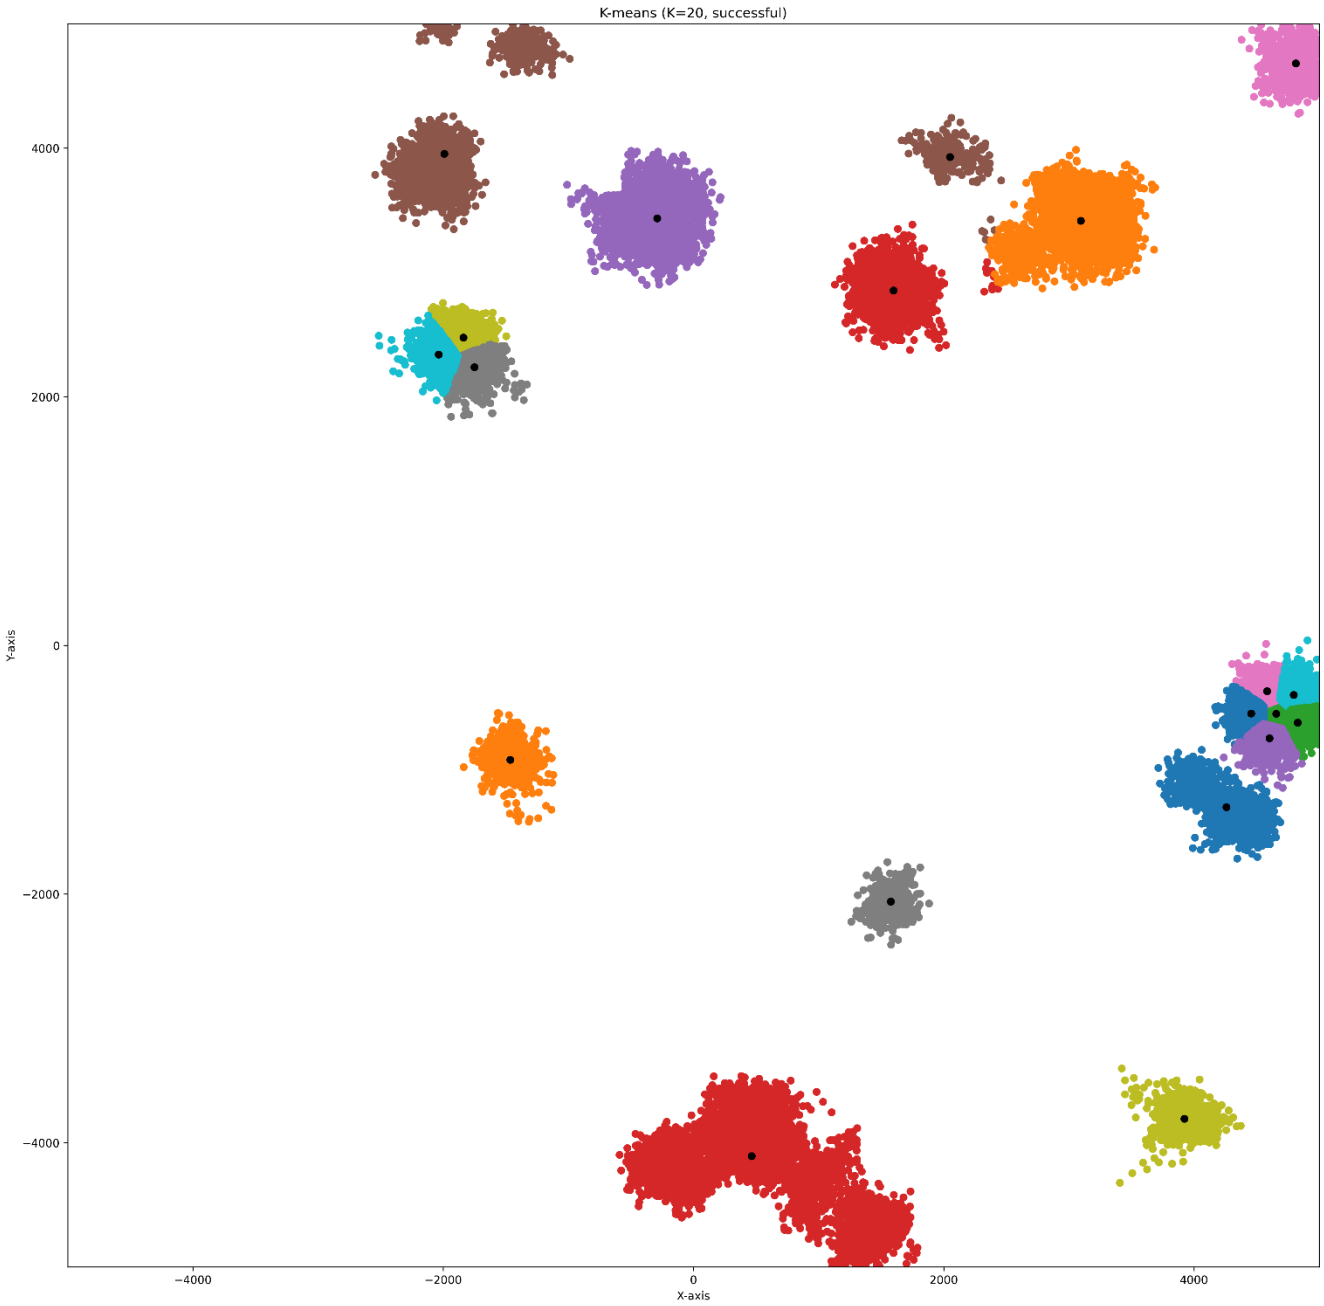

Oleksandr Oksanich, AIS ID: 122480

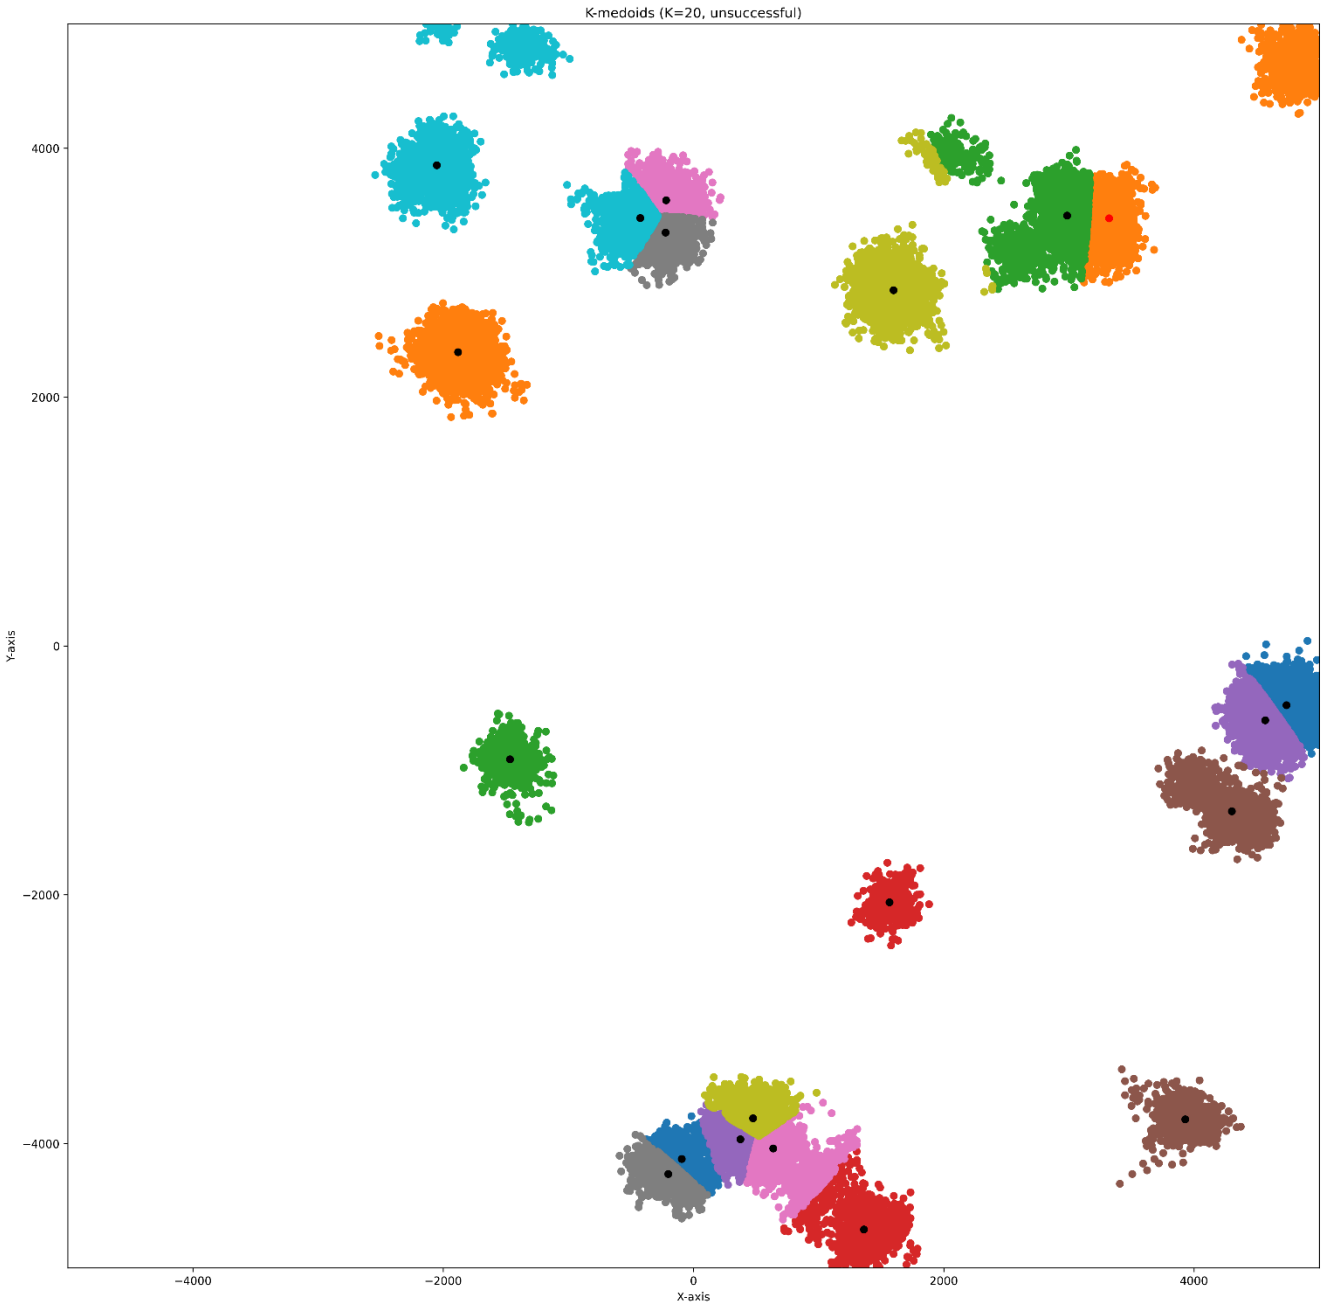

Oleksandr Oksanich, AIS ID: 122480

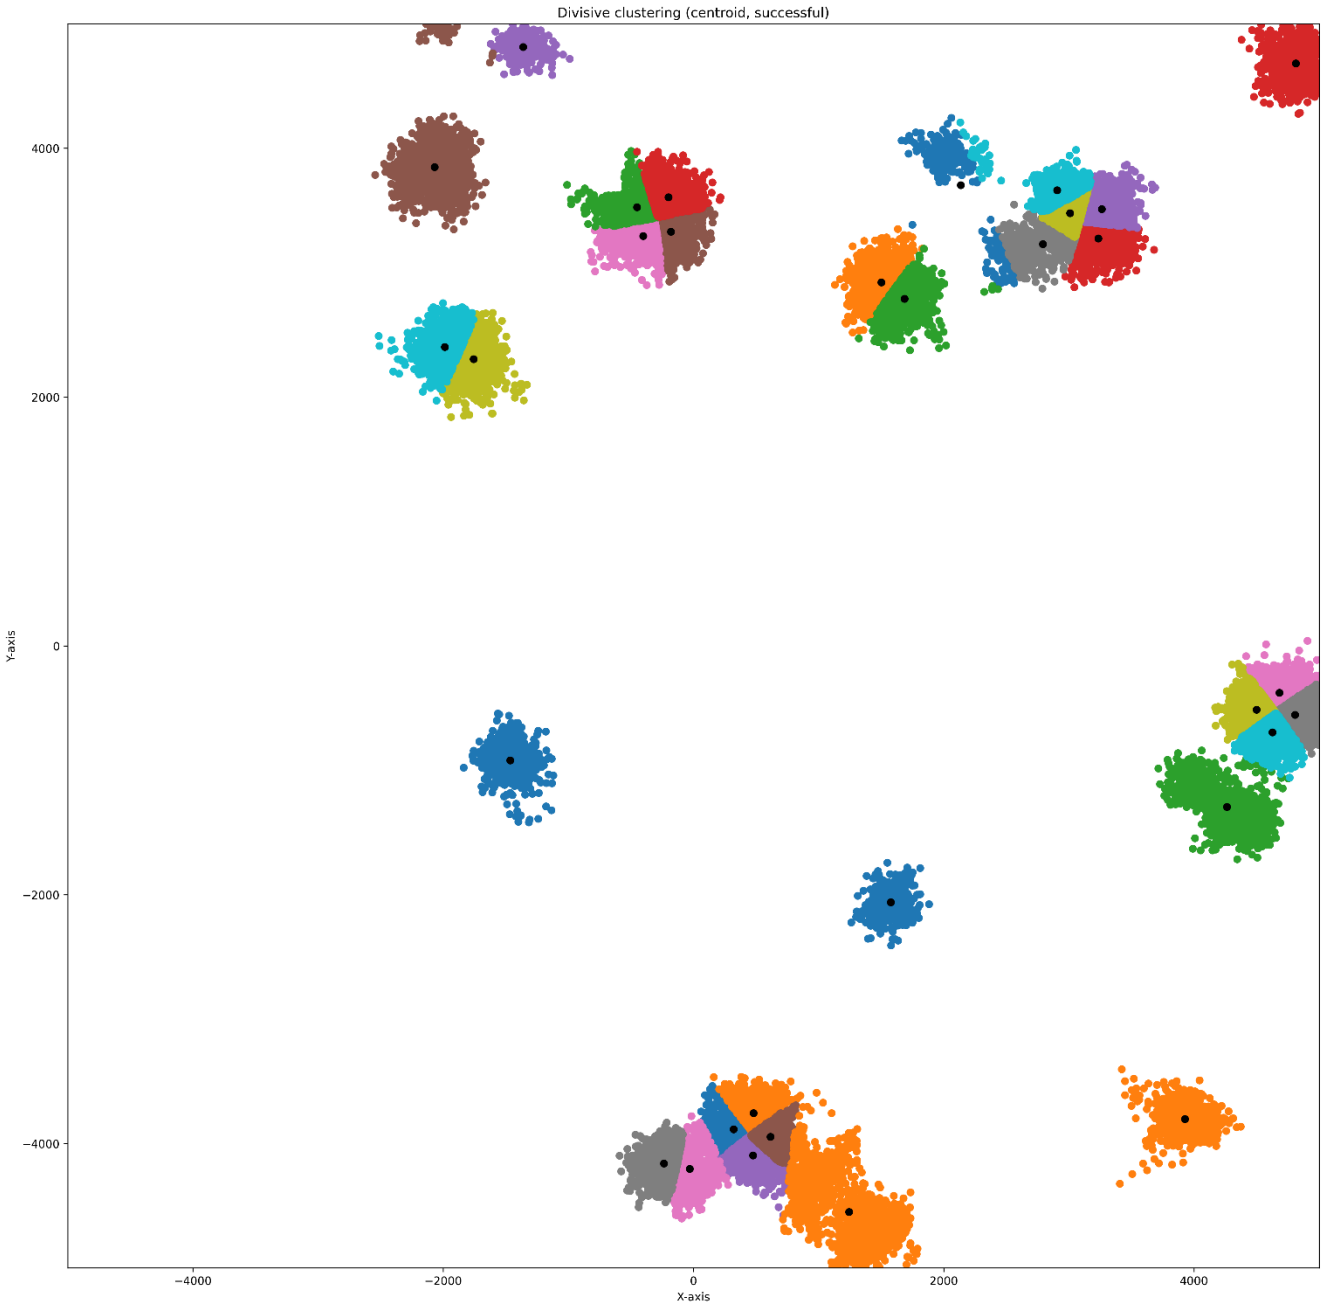

Oleksandr Oksanich, AIS ID: 122480

2. príklad

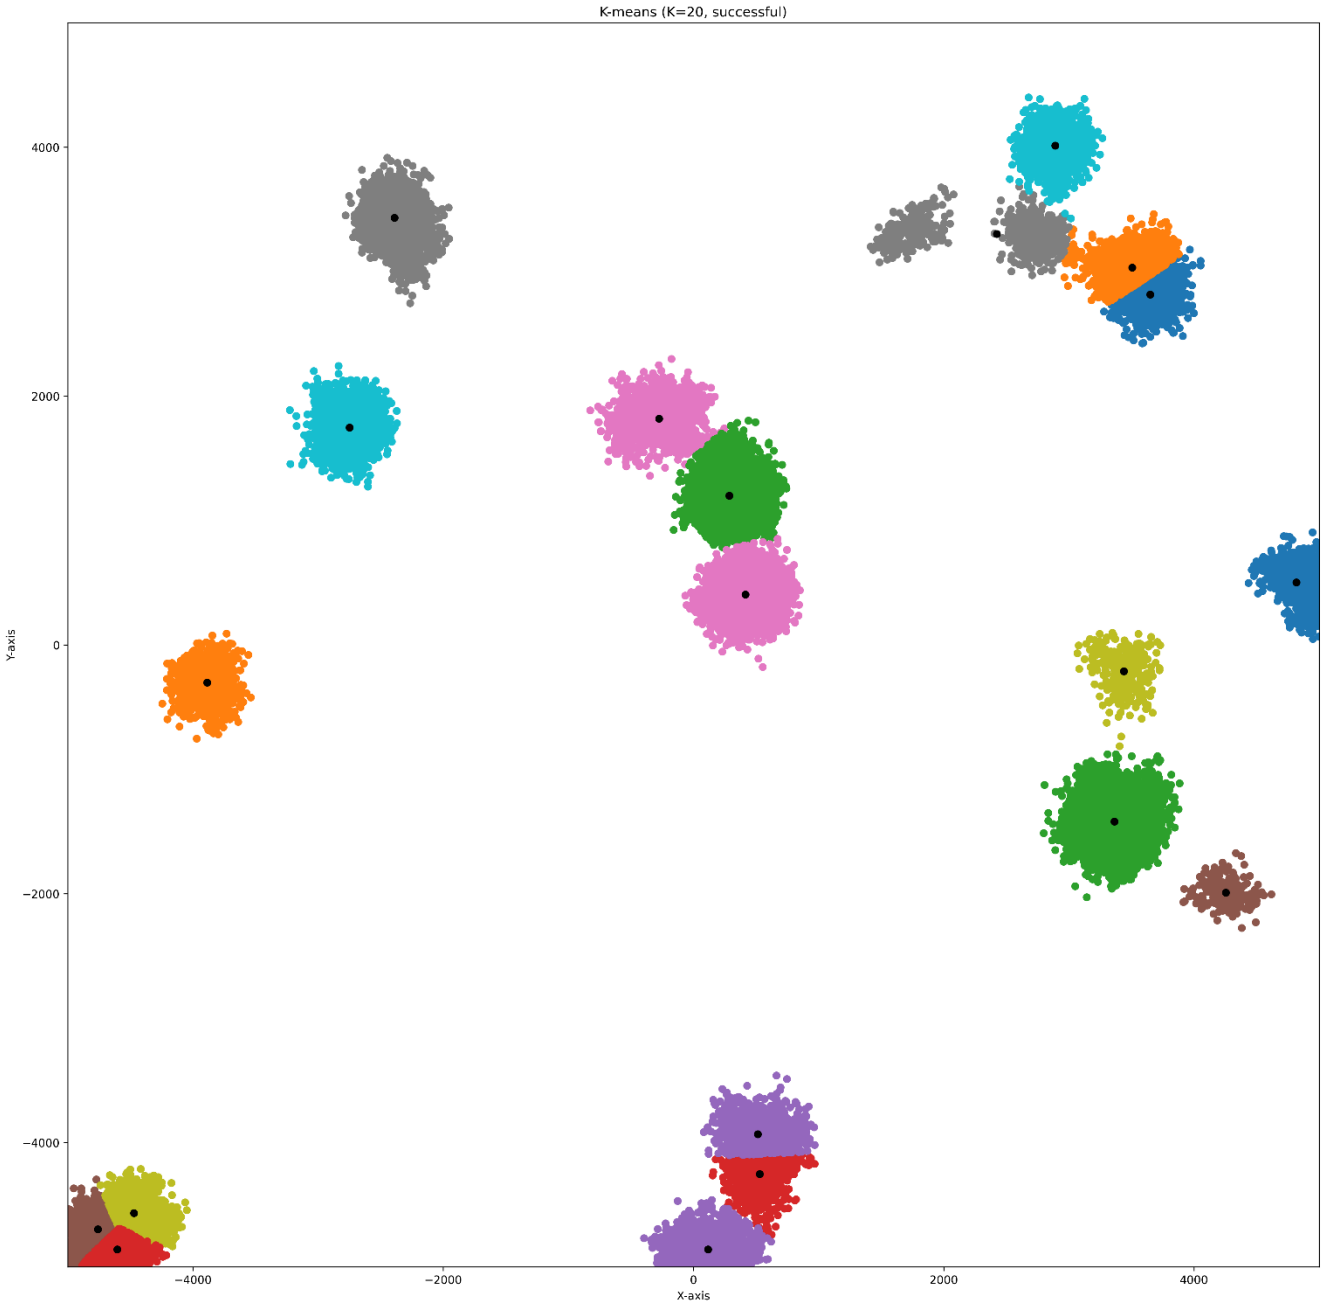

Oleksandr Oksanich, AIS ID: 122480

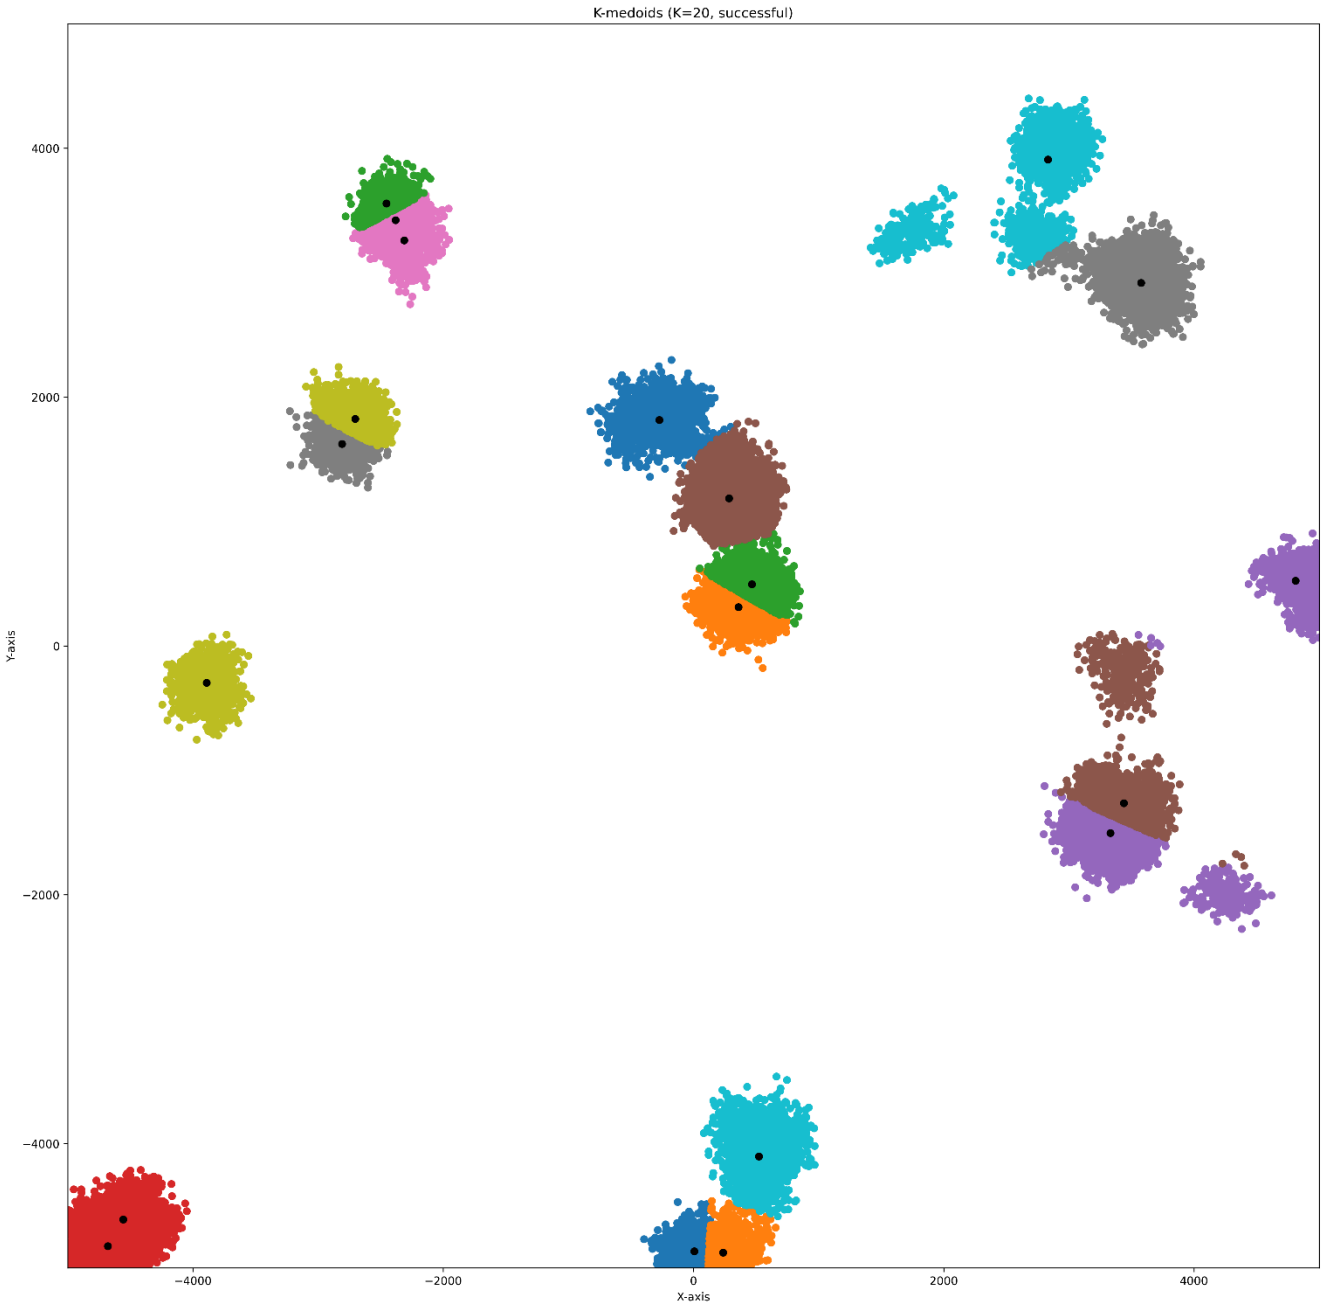

Oleksandr Oksanich, AIS ID: 122480

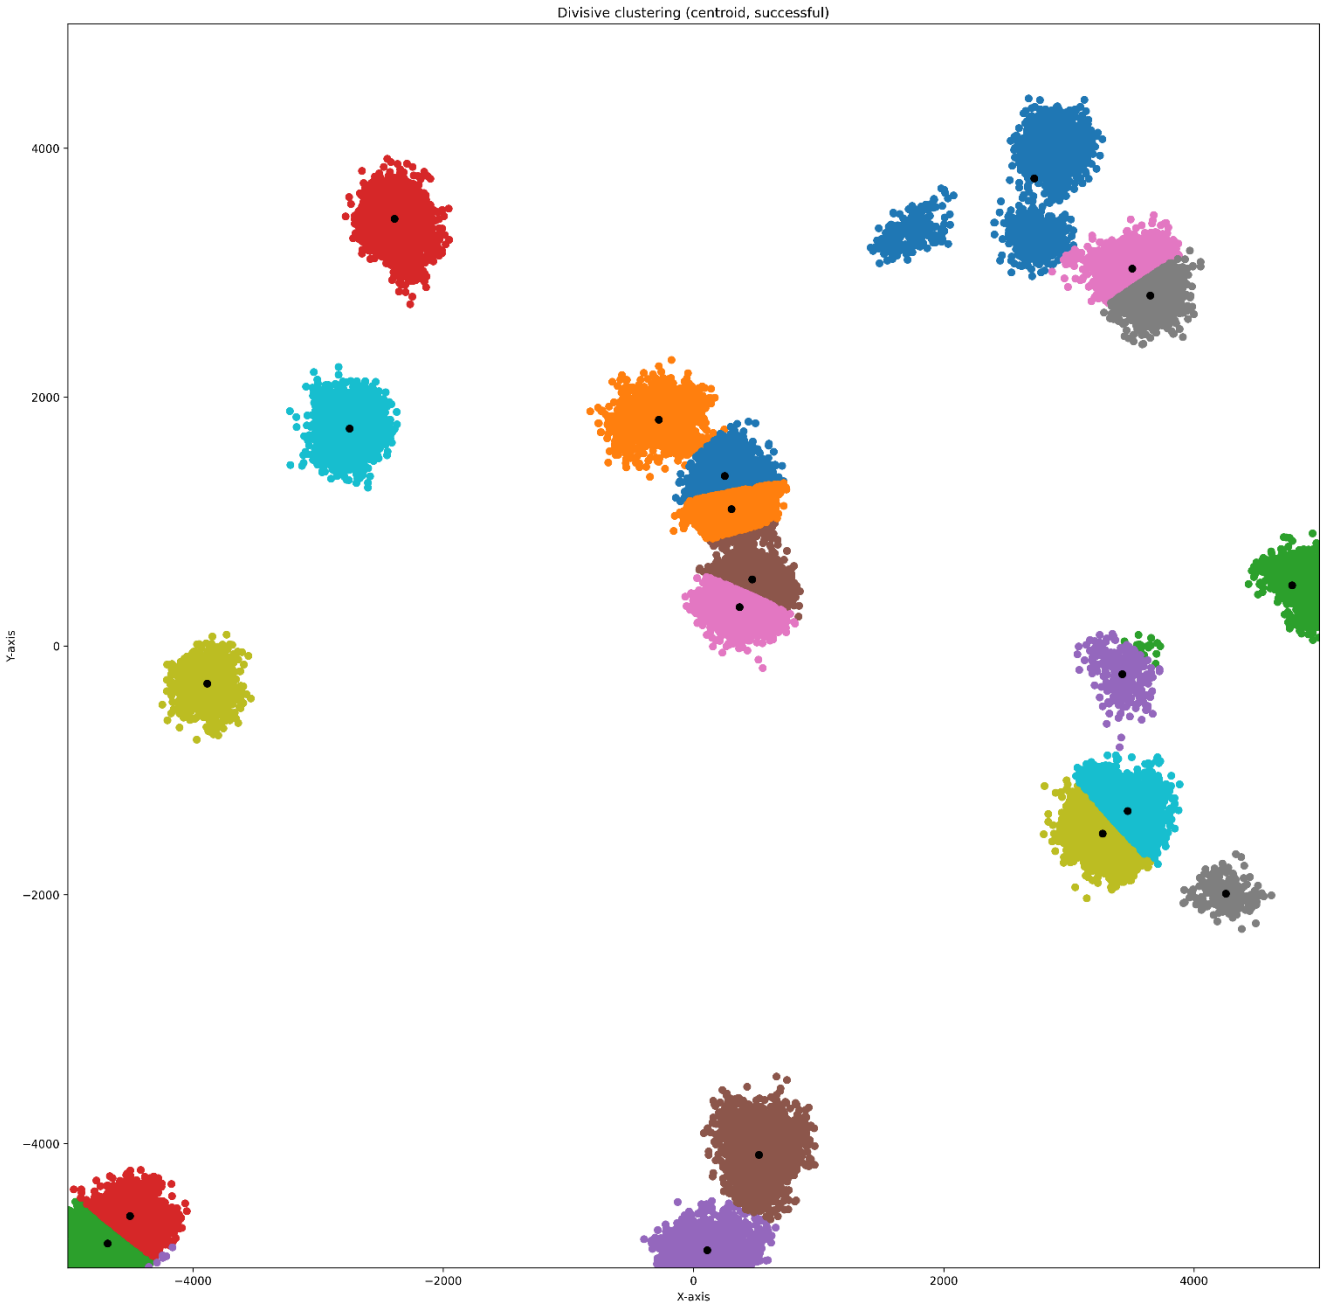

Oleksandr Oksanich, AIS ID: 122480

3. príklad

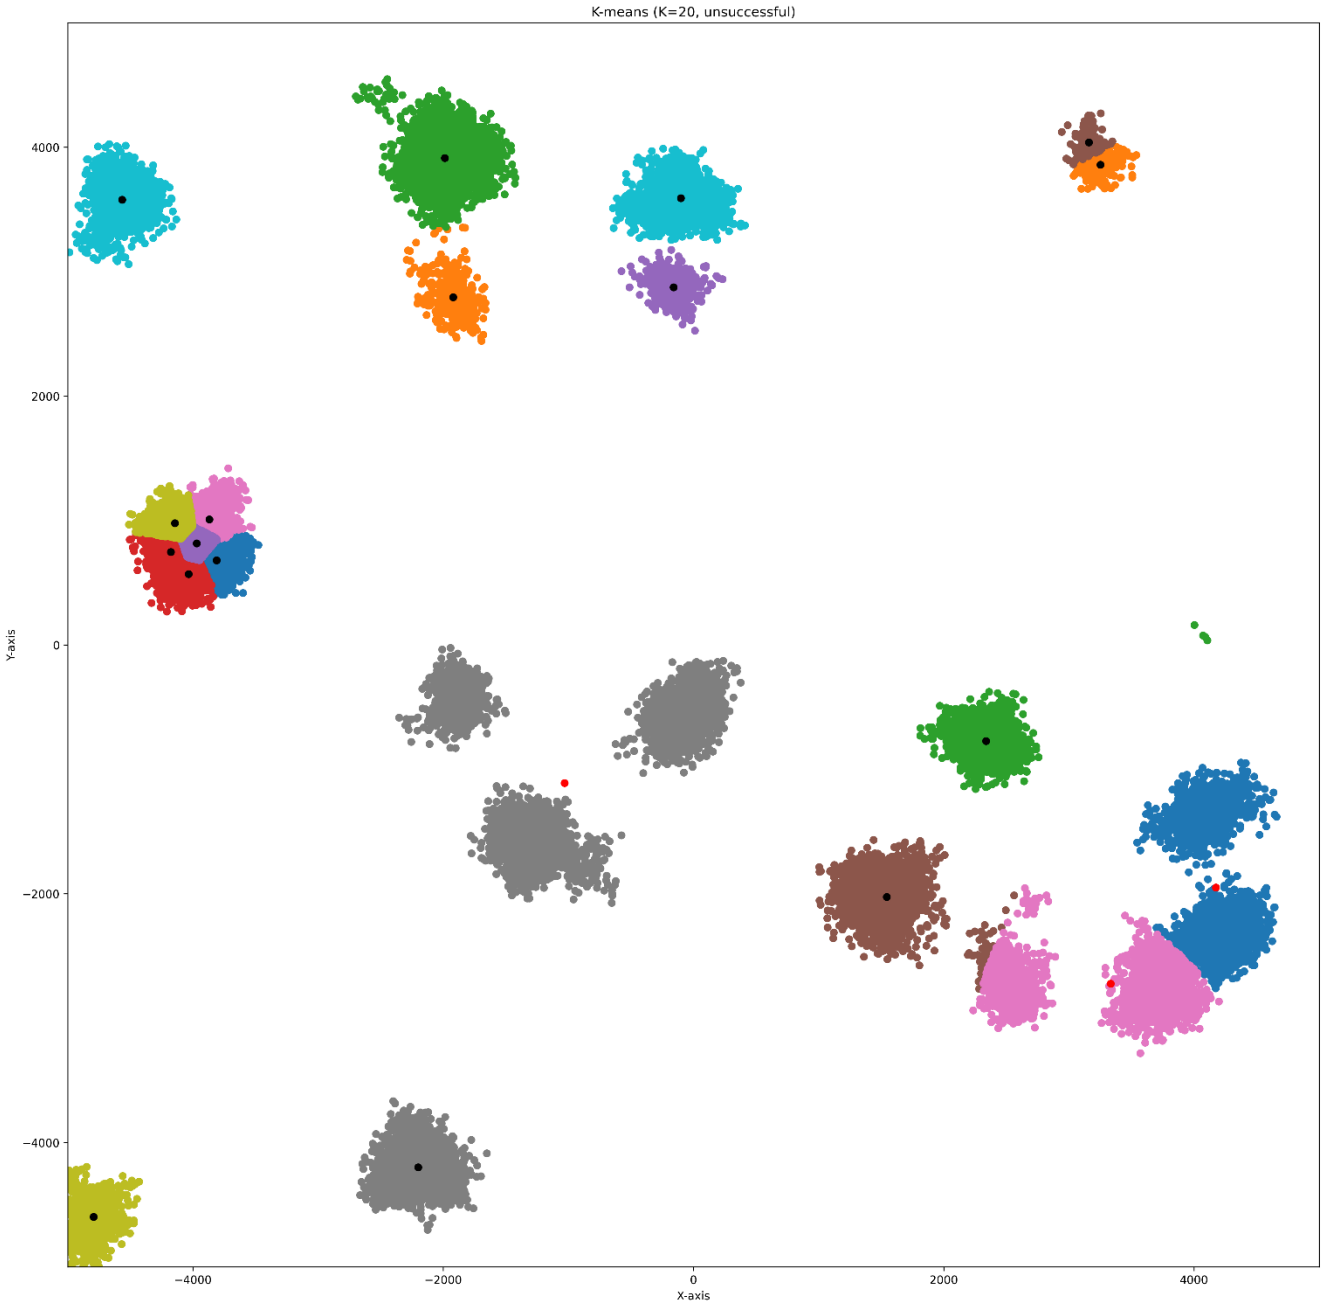

Oleksandr Oksanich, AIS ID: 122480

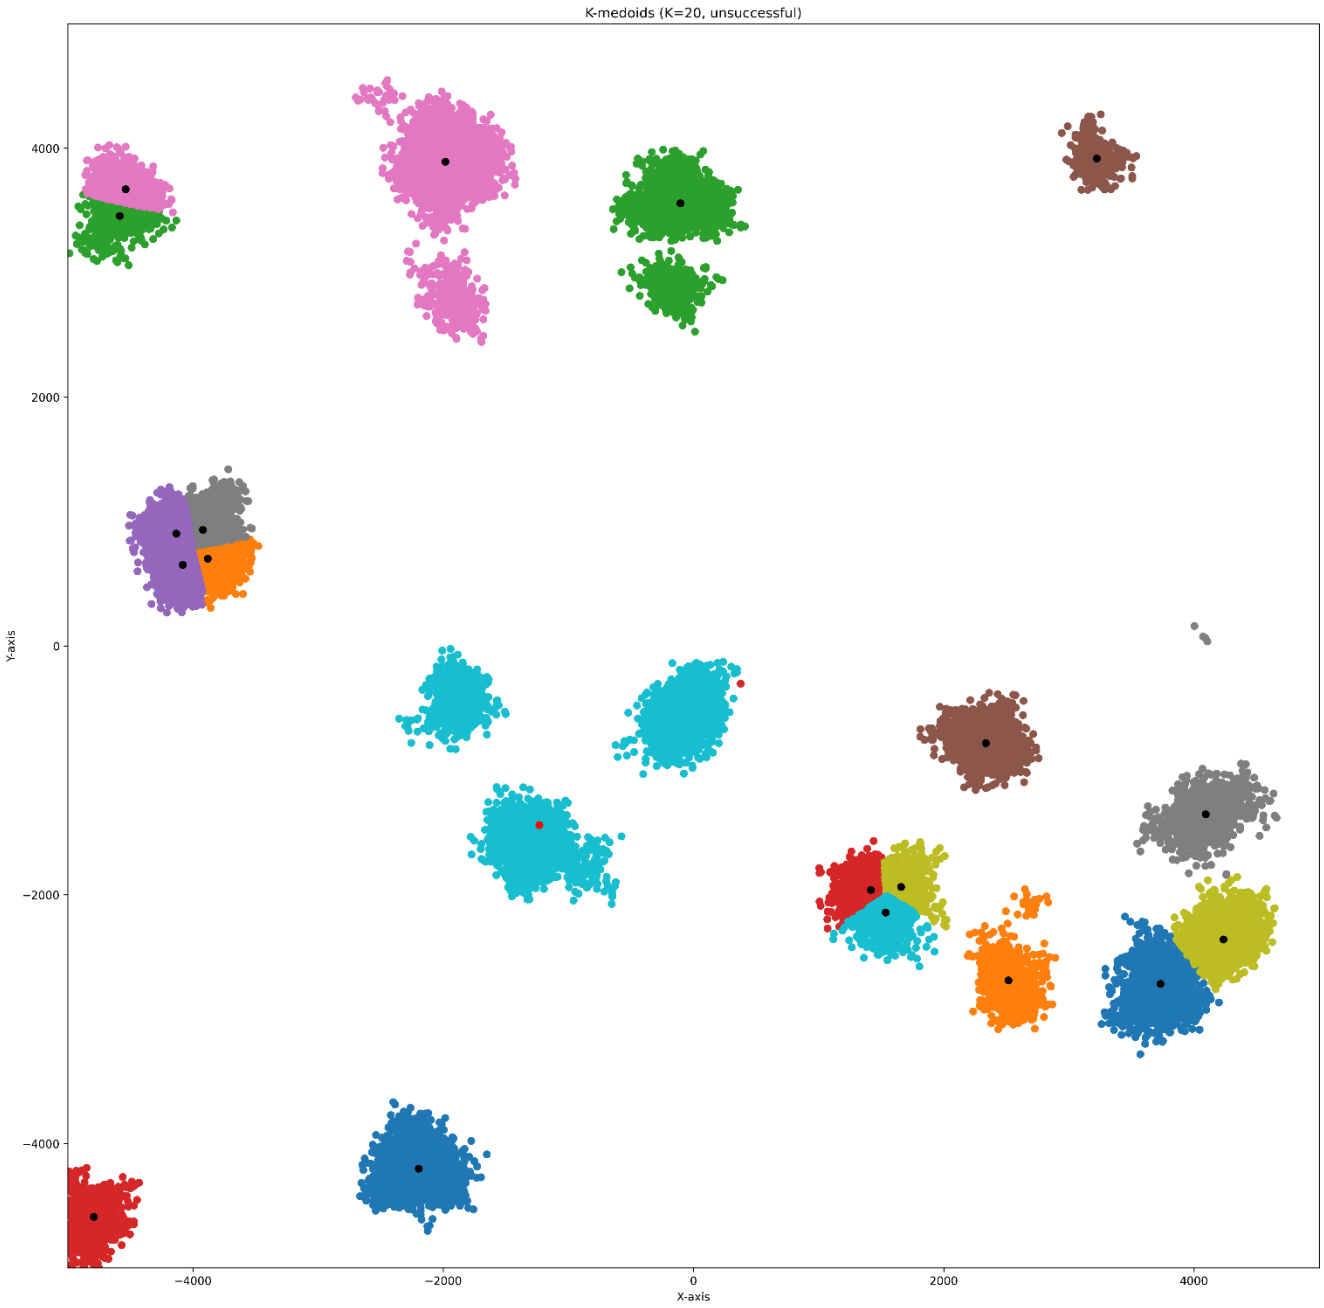

Oleksandr Oksanich, AIS ID: 122480

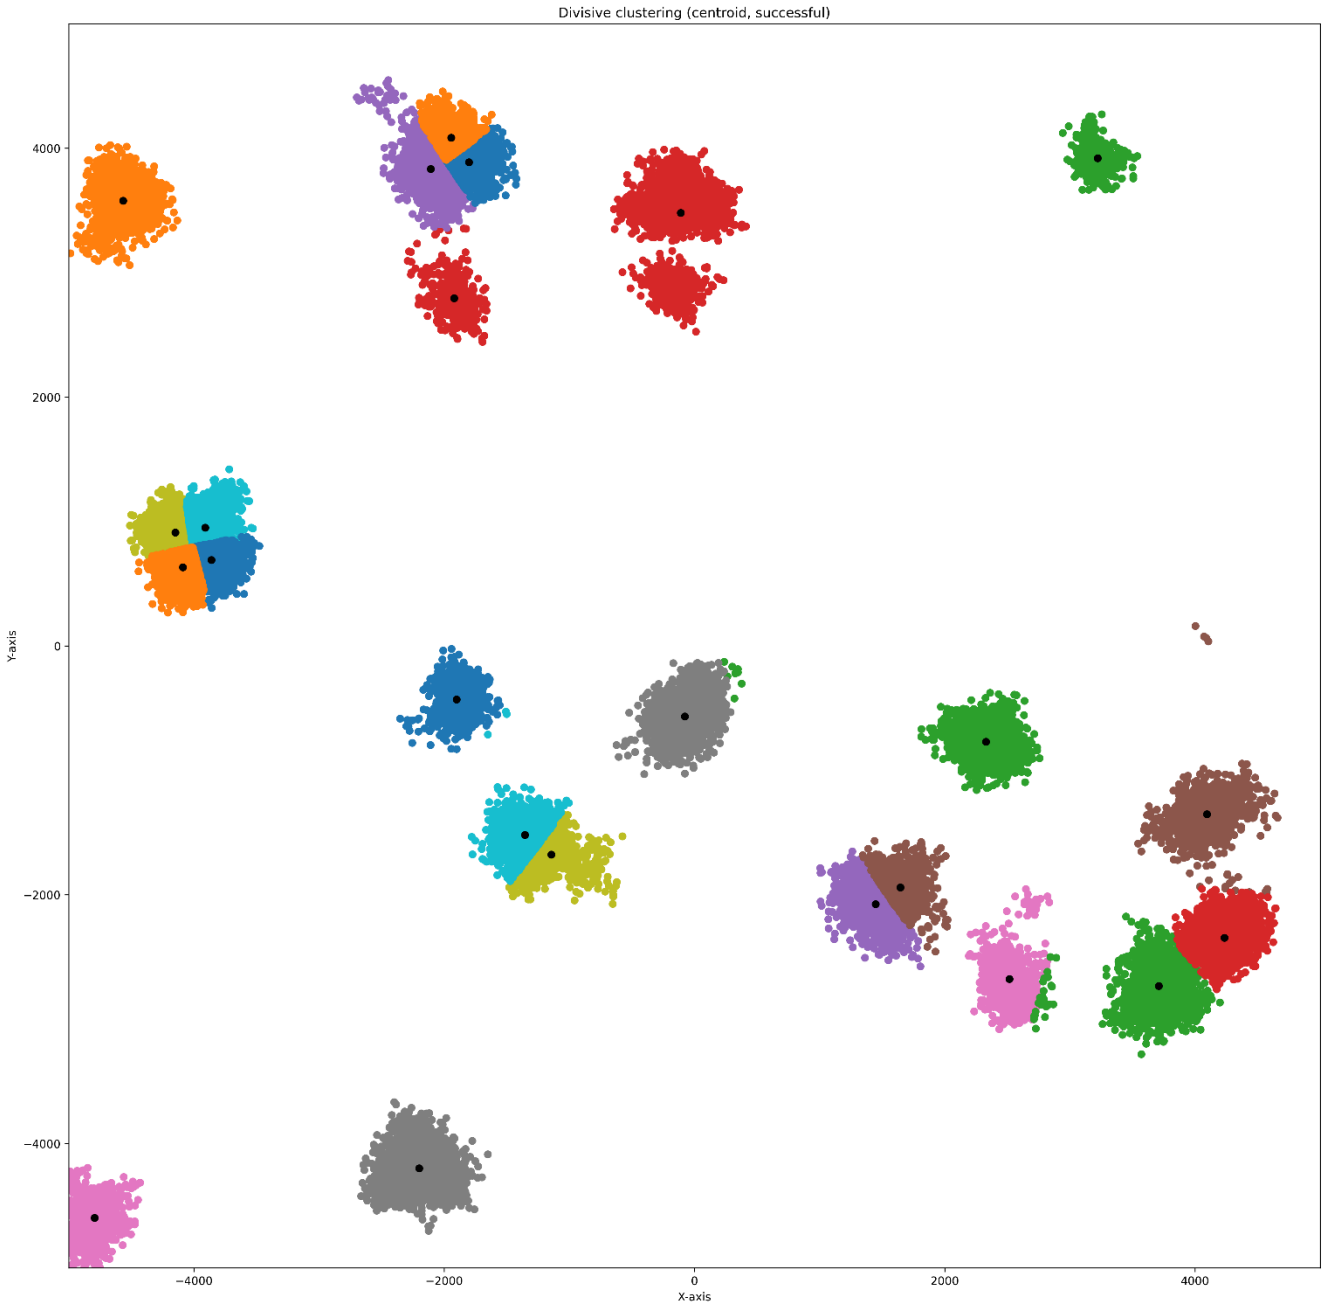

Záver

Na záver možno povedať, že implementované zhlukovacie algoritmy, konkrétne K-means (K=20), K-medoids (K=20) a divízne zhlukovanie (pomocou K-means s K=2), vykazovali v danom kontexte rôznu mieru úspešnosti a výpočtovej efektívnosti.

K-means dosiahol úspech pri zhlukovaní 2 z 3 prípadov. Pri rozdelení údajov do zhlukov preukázal primeranú úroveň účinnosti. S priemerným časom spracovania 30.26 sekundy bol v porovnaní s K-medoids pomerne efektívny.

K-medoids bol úspešný v 1 z 3 prípadov, čo znamená nižšiu úspešnosť v porovnaní s K-means pre tieto tri datasety. Výpočtový čas pre K-medoids bol výrazne vysoký, v priemere 855.79 sekundy, kvôli spôsobu aktualizácie medoidov zhluku, čo prispelo k jeho dlhšiemu času behu.

Oleksandr Oksanich, AIS ID: 122480

Divízne zhlukovanie dôsledne dosiahlo úspešné zhlukovanie, pretože je štruktúrované tak, že úspešnosť je hlavná ukončovacia podmienka v tejto implementácii. Z hľadiska rýchlosti výrazne prekonal K-means aj K-medoids, pričom priemerný čas spracovania bol 4.26 sekundy, čo z neho robí najrýchlejší spomedzi testovaných algoritmov.